

UNIVERSITÀ
DI TRENTO

Dipartimento di Ingegneria e Scienza dell'Informazione

Corso di Laurea in
Ingegneria Informatica, delle Comunicazioni ed Elettronica

Elaborato finale

Segmentazione automatica ad eventi basata sull'Event Segmentation Theory

Supervisore
Prof.ssa Giovanna Varni

Laureando
Emiliano Finetti
209076

Anno accademico 2023/2024

Ringraziamenti

In occasione del conseguimento del mio primo traguardo accademico, desidero esprimere la mia sincera gratitudine a tutte le persone che hanno contribuito a rendere possibile questo successo.
Un ringraziamento speciale va alla Prof.ssa Giovanna Varni per avermi guidato con saggezza e per il suo costante supporto. La sua esperienza e i suoi consigli sono stati fondamentali per la realizzazione di questo lavoro.
Vorrei inoltre ringraziare i miei amici e i colleghi incontrati durante il mio percorso accademico, con i quali ho condiviso diverse sfide e che mi hanno permesso di crescere sia a livello accademico che personale. Il loro supporto e la loro amicizia sono stati inestimabili durante questo percorso.
Un grazie di cuore va anche ai miei amici più stretti, compagni di corso e di vita durante questo viaggio. La loro presenza e il loro incoraggiamento hanno reso più leggeri i momenti di difficoltà, hanno arricchito questa esperienza con gioia e divertimento, rendendo questi anni indimenticabili.
Infine, un ringraziamento profondo a tutta la mia famiglia. Il loro amore incondizionato, la loro pazienza e la loro fiducia nelle mie capacità mi hanno dato la forza di affrontare e superare ogni ostacolo. Senza il loro sostegno, nulla di tutto questo sarebbe stato possibile.

A tutti voi, il mio più sincero grazie.

Sommario

Il problema affrontato all'interno di questo studio è quello della segmentazione, intesa come identificazione e separazione dei diversi eventi di cui è composto un flusso di azioni. Eseguire correttamente tale processo è fondamentale per comprendere la struttura intrinseca di tale sequenza, analizzarne ogni singolo evento e studiare le correlazioni esistenti tra di essi. Pertanto, in molti ambiti di ricerca e in diverse applicazioni pratiche, lo sviluppo di metodi di segmentazione efficaci rappresenta una sfida cruciale.
Questa tesi prende avvio dall'analisi cognitiva dell'Event Segmentation Theory (EST), proponendo un approccio computazionale relativamente alla percezione di tipo sensoriale, in particolare al movimento e all'interazione di soggetti con oggetti. L'EST suggerisce che gli esseri umani segmentano automaticamente il flusso continuo di informazioni percettive in unità discrete chiamate "*eventi*", basandosi sui cambiamenti osservati nella situazione corrente. Applicare questa teoria per sviluppare metodi di segmentazione automatica può portare a risultati più naturali e accurati rispetto agli approcci tradizionali basati su finestre temporali di lunghezza fissa. Per raggiungere questo obiettivo, è stato raccolto un dataset appositamente concepito, comprendente video di tre scenari distinti. Ciascuno dei video in questione documenta una serie di azioni che coinvolgono interazioni con vari oggetti e la segmentazione manuale di tali video in eventi ha costituito il ground truth di riferimento. Sulla base di questo dataset, sono stati implementati e valutati tre algoritmi distinti: un algoritmo basato sull'energia cinetica, uno basato su una Support Vector Machine (SVM) e uno basato su PELT.
Il primo rappresenta un approccio base alla risoluzione del problema attraverso la ricerca e l'applicazione della soglia di energia cinetica migliore per discernere le diverse unità. Il secondo si basa su una Support Vector Machine (SVM), modello di machine learning supervisionato, che attraverso le diverse caratteristiche legate alla EST estratte dal video, ricerca le diverse unità. Il terzo invece si basa su PELT, algoritmo generalmente utilizzato per individuare punti di cambiamento in un segnale o in una serie temporale, che sfrutta le medesime caratteristiche utilizzate dalla SVM per ricercare le diverse unità, ma che non necessita di esempi precedentemente classificati.
I risultati ottenuti sono stati confrontati con il ground truth, valutando l'efficacia di ciascun algoritmo nel segmentare e identificare gli eventi. Da questi risultati si è mostrato che l'algoritmo più semplice permette di raggiungere un buon livello di segmentazione, seppur limitato nella valutazione di una singola caratteristica estrapolata dai video. Gli approcci ispirati alla EST, invece, hanno mostrato prestazioni contrastanti: il metodo supervisionato ha raggiunto prestazioni più elevate rispetto al primo algoritmo, ottenendo segmentazioni più naturali; il metodo non supervisionato, invece, ha ottenuto prestazioni mediocri se confrontate con quelle dei due algoritmi precedenti.

Indice

Introduzione **1**

1 Stato dell'arte **2**
1.1 Event Segmentation Theory (EST) . . . 2
1.2 Segmentazione . . . 3
1.3 Approcci computazionali alla segmentazione . . . 4

2 Materiali e metodi **5**
2.1 Costruzione del dataset . . . 5
2.2 Segmentazione e annotazione manuale . . . 7
2.3 Rilevamento di posa e oggetti . . . 9

3 Algoritmi **11**
3.1 Metriche utilizzate per la valutazione delle prestazioni . . . 11
3.2 Metodo base: soglia sull'energia cinetica . . . 12
3.3 Metodo supervisionato: Support Vector Machine (SVM) . . . 15
3.3.1 Cos'è una SVM . . . 15
3.3.2 Segmentazione automatica tramite SVM . . . 16
3.4 Metodo non supervisionato: Pruned Exact Linear Time (PELT) . . . 19
3.4.1 Cos'è PELT . . . 19
3.4.2 Segmentazione automatica tramite PELT . . . 19

4 Analisi dei risultati **21**
4.1 Metodo a soglia . . . 21
4.2 Metodo supervisionato . . . 22
4.3 Metodo non supervisionato . . . 24
4.4 Sintesi delle prestazioni . . . 25

Conclusioni **26**

Bibliografia **28**

Introduzione

L'analisi e l'annotazione semantica di immagini e video rappresentano un campo di ricerca cruciale nell'ambito dell'intelligenza artificiale e del machine learning, con applicazioni che spaziano dalla sorveglianza alla medicina, fino all'intrattenimento e ai social media. La capacità di segmentare automaticamente partendo dai dati derivanti da video è fondamentale per migliorare l'efficacia degli algoritmi di riconoscimento degli eventi e delle interazioni umane.
In questa tesi, il problema di ricerca affrontato riguarda lo sviluppo e la valutazione di tecniche di segmentazione automatica ad eventi, basate sui principi della scienza cognitiva. In particolare, l'obiettivo è migliorare le tecniche esistenti attraverso l'implementazione di un approccio basato sulla **Event Segmentation Theory** (EST) [22].
Generalmente, il termine *segmentare* si riferisce al processo di suddividere la realtà in unità più piccole [6]. Nell'ambito della presente tesi, tale termine viene utilizzato in un contesto più specifico, ovvero per indicare la suddivisione di un *flusso percettivo* in *eventi*. Questo concetto sottolinea l'importanza di comprendere il mondo circostante attraverso la suddivisione di esso in unità gestibili, processo fondamentale che si sviluppa sin dalla giovane età nell'essere umano, come dimostrato da ricerche condotte su neonati e bambini in età prescolare [3].
La scelta di affrontare questo particolare argomento deriva dalla necessità di superare le limitazioni delle tecniche di segmentazione automatica tradizionali, che spesso si basano su finestre temporali di lunghezza fissa. Questi approcci possono risultare in confini di unità collocati a metà di un'interazione, compromettendo l'osservazione e l'annotazione accurate del comportamento umano. Al contrario, l'approccio ispirato dalla EST promette di fornire segmentazioni più naturali e comprensibili, migliorando la qualità complessiva delle annotazioni. Gli obiettivi principali di questa tesi sono lo sviluppo, la valutazione e il confronto dei risultati di tre algoritmi: un algoritmo basato unicamente sull'energia cinetica, uno basato su una Support Vector Machine (SVM) e uno basato su PELT.

Il Capitolo 1 illustra come il processo della segmentazione sia trattato a livello teorico, soffermandosi principalmente sulla teoria cardine di questo studio, la Event Segmentation Theory (EST) [22]. Teoria che approfondisce i metodi utilizzati dalla mente umana per suddividere inconsciamente gli eventi.
Il Capitolo 2 è dedicato alla descrizione del dataset utilizzato per il test degli algoritmi. Dataset composto da 28 video, autonomamente registrati, ognuno dei quali appartiene a uno di tre scenari differenti, in cui sono stati coinvolti un solo soggetto e molteplici oggetti diversi. Rispetto a tale dataset si esaminano quali siano stati i passaggi che sono stati effettuati, quali siano gli strumenti utilizzati e a quale scopo.
Il Capitolo 3 illustra i tre algoritmi implementati.
Nel Capitolo 4 viene effettuata un'analisi statistica non parametrica dei risultati ottenuti dai tre algoritmi, in cui vengono messi a confronto i risultati ottenuti dai tre algoritmi con il ground truth, ovvero l'insieme dei video segmentati manualmente.
Infine, il Capitolo 5 è interamente dedicato alle conclusioni, in cui vengono riassunti e commentati i risultati ottenuti, proponendo possibili sviluppi futuri.

Capitolo 1

Stato dell'arte

In questo capitolo si delinea il contesto teorico su cui si fonda la presente tesi.
Inizialmente viene analizzato il problema a livello cognitivo, approfondendo il complesso processo attraverso cui la mente umana segmenta gli eventi. Successivamente, si affronta la sfida pratica dell'applicazione concreta di tale teoria, focalizzandosi soprattutto sulla definizione di un'unità temporale significativa. Infine, vengono esaminate diverse metodologie e algoritmi precedentemente impiegati per mettere in pratica questa teoria, evidenziando le loro peculiarità e limitazioni.

1.1 Event Segmentation Theory (EST)

Questa tesi pone le sue fondamenta all'interno di una teoria legata all'ambito della Psicologia Cognitiva: la Event Segmentation Theory [22]. Secondo tale teoria gli esseri umani suddividono, inconsciamente e in modo automatico un flusso continuo di informazioni percepite in unità discrete chiamate "eventi". Questo processo di suddivisione inconscio è mosso da una rappresentazione cognitiva, o un modello, dell'evento in corso.
La segmentazione ad eventi è guidata principalmente da due tipologie di percezioni: sensoriali, come colore, suono e movimento, oppure concettuali, come interazioni causa effetto e obiettivi dei soggetti.
Prendiamo ad esempio l'atto di preparare la tavola, un esempio di percezione sensoriale è lo spostamento di un bicchiere da un punto A a un punto B, in cui viene rilevato il movimento di un oggetto. Sempre all'interno di questo esempio, il raggiungimento dell'obiettivo principale del soggetto, ovvero completare l'apparecchiamento, costituisce un esempio di percezione di tipo concettuale.
Generalmente la prima tipologia di percezione si concentra maggiormente sul movimento degli oggetti e delle persone, mentre la seconda tipologia pone maggior attenzione agli obiettivi dei soggetti coinvolti. Gli esseri umani, infatti, tendono a segmentare gli eventi nei punti in cui le caratteristiche del movimento cambiano, come le accelerazioni rapide o il raggiungimento di una distanza minima o massima tra gli oggetti e il successivo allontanamento, oppure quando avviene un cambiamento negli obiettivi dei soggetti coinvolti.
Elemento fondamentale per segmentare consiste nell'individuare i confini stessi di ogni evento, i boundary, i quali rappresentano il punto di inizio e di fine di un segmento. Nel caso della percezione sensoriale questo boundary viene percepito quando avviene un cambio repentino di una delle caratteristiche del movimento, del suono o della luminosità percepita, nell'esempio di prima il cambio di posizione di un oggetto. Nel caso della percezione concettuale invece, viene percepito un boundary nel momento in cui cambiano le caratteristiche di contesto sociale dell'evento stesso, percepibili dal soggetto osservante paragonando la propria conoscenza pregressa con la rappresentazione dell'evento in corso.

In base a [21] l'individuazione di un boundary tra un segmento e il successivo, avviene a seguito del cambiamento di una, o anche più di una, di queste 7 dimensioni:

1. **tempo**: il ritmo e il tempismo delle diverse azioni e interazioni coinvolte nell'evento;
2. **spazio**: la direzionalità dei movimenti dei soggetti e degli oggetti;
3. **oggetti**: le interazioni che avvengono tra i soggetti e gli oggetti;
4. **soggetti**: il posizionamento dei soggetti nell'area di svolgimento dell'evento;
5. **interazione tra i soggetti**: quali modelli di interazione vengono seguiti dai soggetti coinvolti nell'evento;
6. **cause**: la causalità tra le azioni e interazioni che vedono coinvolti soggetti e oggetti;
7. **obiettivi**: il raggiungimento o meno oppure l'abbandono di un obiettivo da parte di uno o più soggetti.

Attraverso la visione degli eventi data da questa teoria, è possibile pensare a essi come a parti discrete che possono combinarsi in modi nuovi, e più in generale è possibile pensare al tempo come a un insieme di eventi discreti [22].
All'interno di questa tesi si andrà ad analizzare la segmentazione relativamente alle prime tre dimensioni: tempo, spazio e oggetti.

1.2 Segmentazione

Questo processo di suddivisione ha origine, come descritto nella sezione precedente ed esemplificato in 1.1, nell'individuazione di differenti eventi all'interno di un singolo flusso percettivo. I confini (boundaries) di queste unità non sono però percepiti in modo assoluto e unanime, anzi, in accordo con [13], la percezione dei boundaries di un evento, a livello umano, non viene effettivamente rilevata ma viene prevista. Di conseguenza, l'individuazione del numero di eventi e di boundaries di questi ultimi non sono definiti in modo assoluto. Per esempio, se due individui procedessero con la segmentazione dello stesso flusso, otterrebbero probabilmente un differente numero di eventi e con ancor più probabilità quest'ultimi non avrebbero i medesimi boundaries.
Ciò avviene per due motivi principali:

- differenti individui possono effettuare la segmentazione a livelli di granularità differente, ottenendo come risultato un numero differente di unità;
- sebbene venga identificato il medesimo evento, vi sarà una differenza, per quanto minima, tra i rilevamenti dei boundaries da parte dei differenti individui.

Questa variazione tra i boundaries percepiti, e di conseguenza i risultati di eventi ottenuti, da parte di differenti individui, ne rende difficile la generalizzazione. Risulta quindi complesso, ma non impossibile, per un algoritmo ottenere risultati che raggiungano un livello di precisione e coerenza paragonabile alla segmentazione effettuata da parte di un essere umano.
L'obiettivo, infatti, di questa tesi è quello di testare se la segmentazione effettuata attraverso l'utilizzo di caratteristiche estratte con le tecniche descritte nella Event Segmentation Theory, all'interno di determinati scenari, permetta di raggiungere un livello di segmentazione più simile a quella umana.

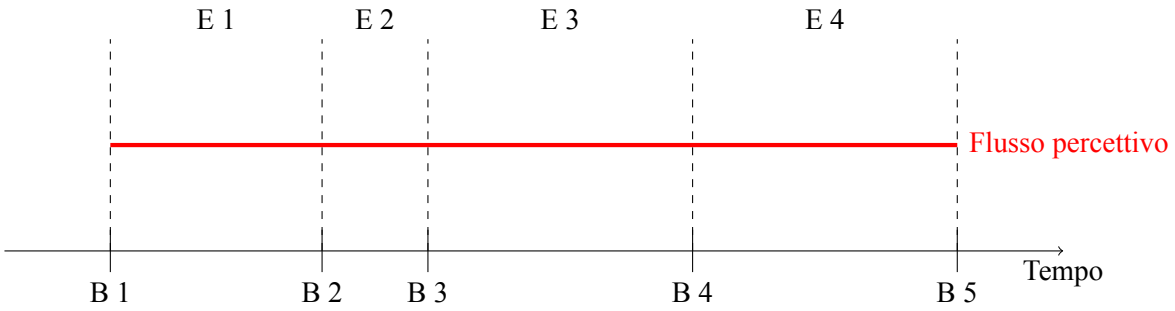


Figura 1.1: Esempio di segmentazione, dove le *E n* sono i diversi eventi e i *B n* sono i diversi boundary.

1.3 Approcci computazionali alla segmentazione

La segmentazione, specialmente nei contesti legati al movimento, è stata oggetto di numerosi studi, con l'introduzione di diverse tecniche descritte in [15]. Tra di esse vi sono: l'utilizzo di soglie, per definire le differenti unità, relative alla direzione della traiettoria del punto preso in esame (e.g.[23], [9], [14]), Dynamic Time Warping (DTW) (e.g.[11]), Hidden Markov Models (HMM) (e.g.[17]), tecniche di classificazione come: le Support Vector Machine (SVM) (e.g.[5]), gli alberi decisionali (e.g.[8]), *k*-Nearest neighbour (*k*-NN) (e.g.[2]) e le reti neurali artificiali (ANN) (e.g.[16]). Tuttavia, questi algoritmi tendono a concentrarsi sulla transizione da un tipo di movimento a un altro, risultando in sovra segmentazioni o anche in segmentazioni non corrette che si perdono la ripetizione dello stesso movimento in successione. Più nello specifico e più nel campo di interesse di questa tesi, in [7] è possibile trovare ulteriori tecniche di applicazione proposte, basate sull'idea della segmentazione come un problema di riconoscimento dell'azione [10], [19] o di change point detection [1], [20].
Studio fondamentale e punto di partenza per questa tesi è stata la tecnica CEST [6], la quale si propone di segmentare gli eventi basandosi sulla Event Segmentation Theory (EST), al fine di fornire le migliori unità possibili per l'annotazione. Infatti, all'interno di questa tesi si è estesa tale tecnica, ponendo maggior concentrazione sull'analisi delle interazioni con gli oggetti.

Capitolo 2

Materiali e metodi

Al fine di testare e confrontare i diversi algoritmi, descritti dettagliatamente nel capitolo successivo, è fondamentale disporre di un dataset adeguato da cui estrarre i dati necessari. Pertanto, questo capitolo si concentra sulla descrizione del processo di costruzione del dataset e delle elaborazioni di preprocessing necessarie che sono state effettuate.

2.1 Costruzione del dataset

Poichè era necessario utilizzare dataset che non fossero troppo ampi e che ne permettessero una facile manipolazione, non trovandone di adeguati, è stato necessario creare un insieme di video specificamente per questo studio.
Prima però di procedere alla registrazione di quest'ultimi, è stato importante selezionare scenari e azioni pertinenti agli obiettivi della tesi, ma anche facilmente rilevabili a livello computazionale. A tal fine, sono stati considerati tre diversi scenari:

- Apparecchiare uno o più posti a tavola;
- Preparare una caffettiera;
- Inscatolare diversi oggetti.

Tutti e tre questi contesti presentano l'esecuzione di numerose azioni, ciascuna finalizzata al raggiungimento di un obiettivo specifico. Queste azioni sono ricche di comportamenti diversificati, tra cui guardare, contare, mimare, puntare e nascondere. All'interno dei video appartenenti allo stesso scenario, sono state introdotte, per alcuni di essi, delle pause da eseguire in momenti diversi durante l'esecuzione. Questo approccio è stato adottato per evitare la ripetitività delle azioni svolte e consentire una generalizzazione più ampia nell'estrazione delle informazioni, indipendentemente dalla natura specifica delle azioni presenti nel video.
Una volta definite le diverse situazioni e le diverse azioni supplementari, si sono quindi registrati 28 video totali, le cui caratteristiche sono elencate nella tabella 2.1.

Situazione	Interazione visiva	Ulteriori dettagli
Apparecchiamento	contare, puntare	2 posti e pausa
	contare, mimare	2 posti e pausa
	nascondere, puntare	2 posti e pausa
	nascondere, contare	2 posti e pausa
	puntare, mimare	2 posti e pausa
	mimare, puntare	2 posti e uso del telefono
	puntare, nascondere	2 posti e uso del telefono
	contare, puntare	1 posto e pausa
	contare, mimare	1 posto e pausa
	contare, nascondere	1 posto e pausa
	puntare, mimare	1 posto e pausa
	puntare, nascondere	1 posto e pausa
	contare, mimare	1 posto e uso del telefono
	puntare, mimare	1 posto e uso del telefono
Preparazione caffettiera	contare, puntare	pausa
	contare, mimare	pausa
	contare, nascondere	pausa
	puntare, mimare	pausa
	puntare, nascondere	pausa
	contare, puntare	telefono
	puntare, mimare	telefono
Inscatolamento	contare, puntare	pausa
	contare, mimare	pausa
	contare, nascondere	pausa
	puntare, mimare	pausa
	puntare, nascondere	pausa
	contare, mimare	telefono
	puntare, nascondere	telefono

Tabella 2.1: Dettagli di tutti i video registrati.

Ciascuno di questi video è stato registrato utilizzando uno Xiaomi Mi 9T Pro, con una risoluzione di 1080x1920 pixel, un frame rate di 60 fps e un rapporto d'aspetto pari a 9:16. Successivamente, per alleggerire il carico computazionale per la manipolazione ed estrazione dei dati necessari, attraverso FFmpeg[1], la risoluzione è stata ridotta a 720x1280 pixel e il framerate a 30 fps, mantenendo invariato il rapporto d'aspetto.
È importante notare che ogni video nel dataset presenta un singolo soggetto, semplificando così l'analisi. Questa scelta è stata fatta in considerazione del fatto che il focus principale della tesi non riguarda la segmentazione delle interazioni sociali all'interno degli eventi, ma piuttosto l'interazione di un soggetto con diversi oggetti.

2.2 Segmentazione e annotazione manuale

Per creare il ground truth, necessario per il confronto con i risultati degli algoritmi, è stato fondamentale segmentare e annotare manualmente ogni azione presente in ciascun video registrato. Questa operazione è stata condotta utilizzando la versione 6.7 del software ELAN[2], che consente di suddividere il video in segmenti temporali e assegnare loro specifiche annotazioni, come esemplificato nella Figura 2.1.
Prima di procedere con la segmentazione e annotazione, è stato definito un insieme di etichette ben definito, di modo che ogni azione in ogni video sia associabile a una di esse. Questo è stato fatto per permettere la corretta definizione dei boundaries di ogni evento in ciascun video.
Le etichette che sono state definite sono riportate in Tabella 2.2.

Interazione	Punto di inizio	Punto di fine
Prendere	Momento in cui il soggetto entra in contatto con l'oggetto	Momento in cui l'oggetto smette di essere mosso verso il soggetto che lo ha preso e inizia a esser spostato verso il tavolo
Lasciare	Essendo l'oggetto in contatto con il soggetto, è il momento in cui quest'ultimo inizia a muoverlo verso il tavolo	Momento in cui si cessa di toccare l'oggetto
Aprire	Momento in cui si tocca l'oggetto con la seconda mano	Momento in cui la seconda mano cessa di toccare l'oggetto
Chiudere	Momento in cui si tocca l'oggetto con la seconda mano	Momento in cui la seconda mano cessa di toccare l'oggetto
Versare	Momento in cui si inizia a portare l'oggetto verso il tavolo, inclinandolo	Momento in cui si comincia a portare l'oggetto verso il soggetto
Inserire	Toccando già l'oggetto, è il momento in cui si porta l'oggetto verso un contenitore	Momento in cui si cessa di toccare l'oggetto
Guardare	Momento di osservazione degli oggetti, senza avere un'interazione diretta con essi	Momento in cui si tocca un oggetto o si solleva esplicitamente una mano
Contare / Puntare Mimare / Nascondere	Momento in cui si solleva esplicitamente una mano	Momento in cui la mano torna nella posizione iniziale

Tabella 2.2: Definizione delle diverse etichette assegnate alle azioni.
Osservando la tabella si può notare come *aprire* e *chiudere* abbiano le stesse definizioni. Questo è dovuto al fatto che i boundary sono percepiti al cambiamento delle medesime caratteristiche, ma l'azione che avviene tra i due boundary è completamente differente.

Oltre alla segmentazione e all'annotazione volta alla creazione del ground truth per le successive analisi, in ogni video si è estratta e annotata manualmente anche l'informazione riguardante la modalità di interazione con gli oggetti. Quest'ultima ha assunto uno di questi tre valori per ognuno dei segmenti estratti:

- Interazione con una mano;
- Interazione con due mani;
- Interazione tramite lo sguardo.

[2] `https://archive.mpi.nl/tla/elan`

È importante far notare che non sempre i segmenti relativi a diverse interazioni corrispondono a diverse modalità. Basti pensare alle azioni che compongono il prendere e lasciare un oggetto: le interazioni fanno parte di due segmenti differenti, mentre la modalità è unica in quanto, in un caso normale, l'oggetto viene preso da una mano e lasciato dalla stessa.

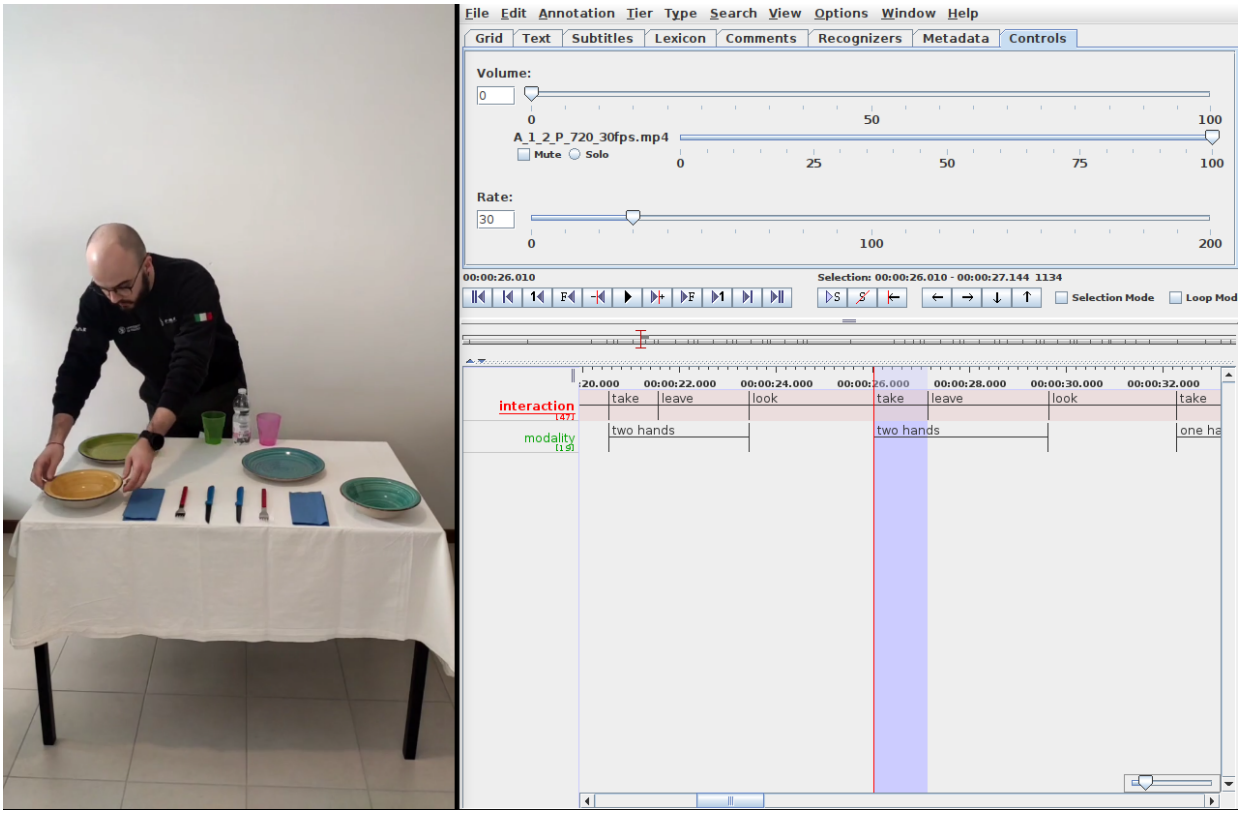


Figura 2.1: Esempio di annotazione manuale di un video.
Sul lato sinistro è presente un frame estratto da uno dei video del dataset. Sul lato destro è visualizzato uno snapshot di ELAN, il software utilizzato per l'annotazione. In questa schermata di ELAN, sono evidenziati alcuni dei controlli disponibili per l'annotazione. Inoltre, sono mostrate anche alcune unità segmentate e annotate secondo i due tipi di annotazione utilizzati: *Interaction* e *Modality*.

Per ciascun video, è stato generato un file nel formato `.eaf` (ELAN Annotation Format) tramite l'utilizzo di questo software, contenente informazioni dettagliate sulla segmentazione e sulle annotazioni effettuate. In aggiunta, è stato estratto un file `.txt` per ogni video, in cui è presente un elenco delle unità segmentate. Questo file fornisce, per ciascuna unità: il tipo di annotazione alla quale appartiene l'unità (*Interaction* o *Modality*), il tempo di inizio, il tempo di fine, la durata totale e l'etichetta a essa assegnata.

2.3 Rilevamento di posa e oggetti

Estrarre la posizione del soggetto e rilevare gli oggetti presenti in scena è stato il punto di partenza per l'estrazione dei dati dai video. A tal fine, è stata utilizzata la versione 3.10.12 del linguaggio di programmazione Python[3] in combinazione con il software YOLO (You Only Look Once)[4], versione 8.
Questo software utilizza un algoritmo basato su una singola rete neurale convoluzionale per predire le posizioni degli oggetti direttamente da ciascuno dei frame di ogni video. Funziona suddividendo l'immagine del frame in una griglia e applicando un'analisi convoluzionale su ogni cella della griglia, prevedendo contemporaneamente classe e coordinate dei box contenenti gli oggetti.
Per rilevare la posa invece, utilizza un processo di identificazione e mappatura dei punti chiave del corpo umano, sempre in relazione a ciascun frame di ogni video. Questo avviene grazie all'utilizzo di modelli appositamente addestrati su dataset robusti, come COCO keypoints[5], che sono in grado di gestire le complessità della stima della posa umana.
Utilizzando YOLO sui nostri video registrati, per ognuno dei frame siamo stati in grado di:

- Rilevare la posa del soggetto e fornire le coordinate spaziali, in due dimensioni, di 16 punti chiave appartenenti a essa. Questi punti rappresentano le parti anatomiche significative del corpo umano, come testa, spalle, gomiti, polsi, anche, ginocchia e caviglie. In Figura 2.3 è possibile vedere lo schema di tutti i punti chiave rilevabili da YOLO, mentre in Figura 2.2 è presente un esempio di estrazione della posa.
- Identificare diversi tipi di oggetti all'interno della scena e fornire, per ognuno di essi, una coppia di coordinate spaziali in due dimensioni, che rappresenta la diagonale del bounding box. Quest'ultimo è il rettangolo più piccolo che circonda completamente l'oggetto rilevato e le sue coordinate definiscono la posizione approssimativa dell'oggetto nella scena, esemplificato in Figura 2.4.

Questi dati sono stati successivamente organizzati e memorizzati per ogni video in due file `.txt` distinti: uno contenente le coordinate dei keypoints della posa per ogni frame e l'altro le coordinate degli oggetti rilevati per ogni frame. I dati in entrambi i casi, prima di essere inseriti all'interno dei file, sono stati formattati utilizzando il formato JSON, il quale ne ha permesso l'organizzazione in una struttura gerarchica. Questa modalità di archiviazione ha agevolato la successiva analisi rendendola rapida e dettagliata rispetto alle informazioni estratte dai video.
È importante precisare che, come illustrato nella Figura 2.2, dei keypoints estratti sono stati presi in considerazione solamente quelli appartenenti alla parte superiore del corpo. Questo perché, per l'obiettivo specifico della presente tesi, il focus è stato posto sull'analisi delle interazioni che coinvolgono principalmente le mani e il tronco. Di conseguenza, i keypoints relativi alla parte bassa del corpo non sono stati considerati.

[3] `https://www.python.org`
[4] `https://docs.ultralytics.com`
[5] `https://cocodataset.org`

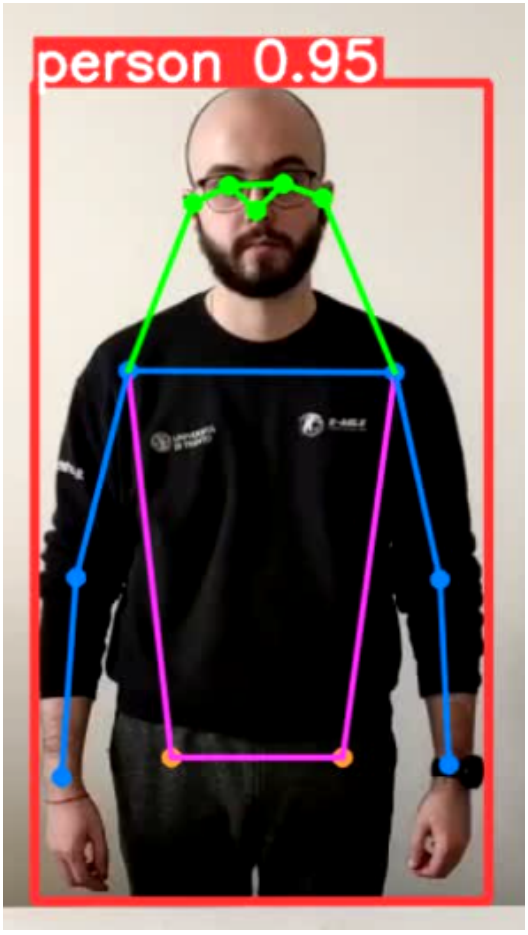


Figura 2.2: Esempio di punti chiave estratti da uno dei video registrati.

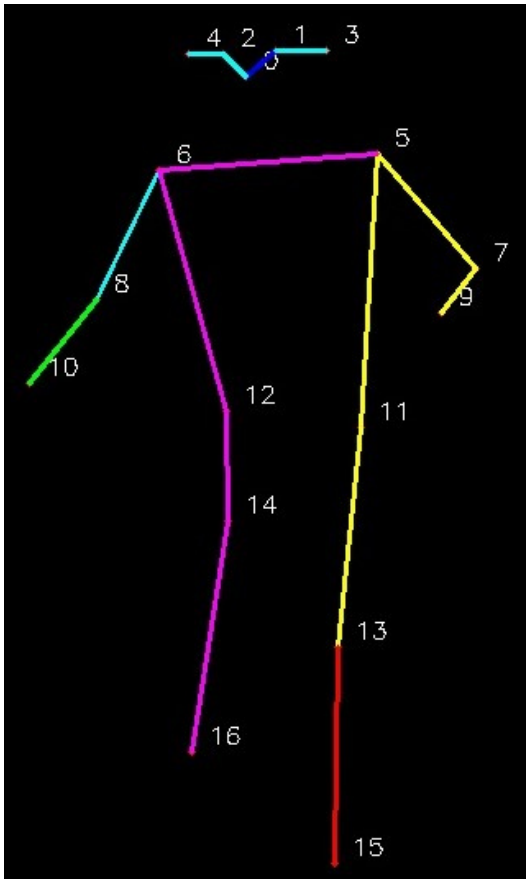


Figura 2.3: Indicazione dei punti chiave che vengono rilevati da YOLO.

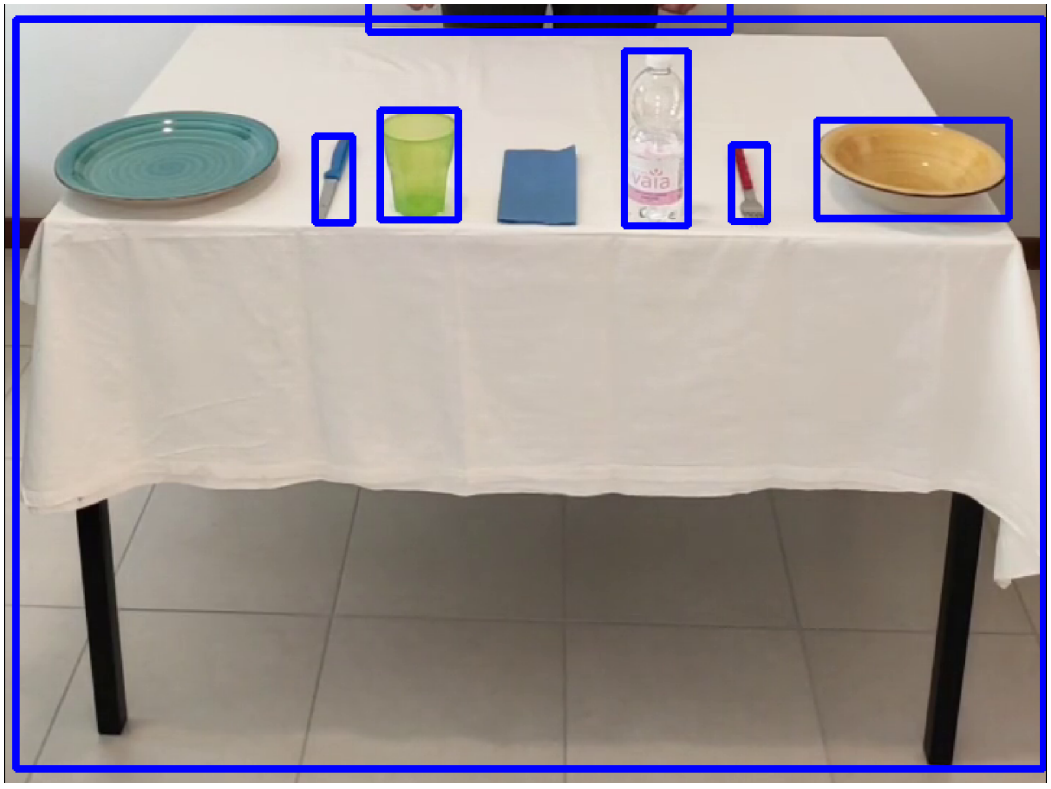


Figura 2.4: Esempio di oggetti rilevati da uno dei video registrati.

Capitolo 3

Algoritmi

In questo capitolo viene dapprima fornita una descrizione dettagliata riguardo la metrica utilizzata per la valutazione di ogni algoritmo e successivamente vengono analizzati i diversi algoritmi sviluppati per implementare la segmentazione automatica ad eventi: un algoritmo basato sull'energia cinetica, uno basato su una Support Vector Machine (SVM) e uno basato su PELT. Per ciascun algoritmo, vengono illustrati il funzionamento generale, le varie manipolazioni dei dati effettuate e, attraverso l'utilizzo di pseudo codice, le specifiche modalità di implementazione adottate nel contesto del presente studio.

3.1 Metriche utilizzate per la valutazione delle prestazioni

Innanzitutto, per l'implementazione dei due algoritmi sono stati utilizzati 6 video per ognuno degli scenari, per un totale di 18 video, di modo da garantire omogeneità nei dati del dataset valutati. I tre algoritmi implementati, descritti successivamente, sfruttano i dati derivanti da tali video e per consentirne un confronto equo, seguono la stessa metrica di valutazione.
Per ognuno dei video segmentati da parte di uno dei tre algoritmi, si è confrontato il risultato ottenuto con il video segmentato manualmente, il ground truth. Il confronto ha paragonato, frame per frame, la classe reale definita dal ground truth, con la classe assegnata dall'algoritmo.
Nel caso in cui la classe nel ground truth fosse pari a 1, ovvero boundary, dal risultato ottenuto dall'algoritmo sono stati considerati i 6 frame precedenti e i 6 successivi, al frame preso in esame. Se uno solo di essi è stato classificato come 1, allora si è considerato un True Positive (TP). Se più di uno è stato classificato come 1 allora si è considerato un True Positive (TP) e $k - 1$ False Positive (FP). Se nessuno di essi è stato classificato come 1, allora è stato considerato un False Negative (FN).
Nel caso in cui invece, partendo dal risultato dell'algoritmo, il frame fosse stato classificato di classe 1, ma considerando 6 frame prima e 6 frame dopo il frame in esame all'interno del ground truth, nessuno di essi fosse classificato come 1, allora si è considerato un FP.
Sommando i risultati ottenuti, è stata costruita la matrice di confusione per poterne calcolare la metrica F1, indice principale utilizzato per la valutazione delle prestazioni. Tale metrica è una misura di valutazione di un modello di classificazione che si ottiene combinando precision e recall dell'algoritmo considerato. La *precision* indica il numero di True Positive diviso il numero di tutti i risultati positivi, mentre la *recall* è il numero di True Positive diviso il numero di tutti i test che sarebbero dovuti risultare positivi. La F1 si ottiene come media armonica tra i due indici ed è stata calcolata con la seguente formula:

$$F1 = 2 \times \frac{(precision \times recall)}{(precision + recall)} \tag{3.1}$$

3.2 Metodo base: soglia sull'energia cinetica

Un primo approccio algoritmico, seppur rudimentale, per tentare di segmentare un flusso di percezioni in eventi, si basa sull'analisi delle variazioni dell'energia cinetica totale. Questo metodo non si affida a finestre temporali prefissate, ma piuttosto alle informazioni intrinseche alle azioni svolte durante l'evento.
Per ogni coppia di frame, l'algoritmo calcola l'energia cinetica di ciascun keypoint, per farlo osserva la variazione di posizione di ognuno di essi nei due frame, così da poterne calcole la velocità. Successivamente, somma i valori di energia cinetica di tutti i keypoint per ottenere l'energia cinetica totale.
L'idea alla base di tale processo è quella che, a livello teorico, l'inizio di una azione prevede il passaggio repentino da una condizione di stabilità a una di movimento, ovvero da una condizione di bassa energia cinetica a una di alta energia cinetica. Il primo passo per implementare questo algoritmo consiste quindi nell' elaborare, per ogni frame di ogni video, la distanza percorsa (in pixel) da ogni keypoint, tra un frame e il successivo. Tenendo in considerazione che il framerate di ogni video è stato ridotto a 30 frame per secondo, è possibile estrarre la velocità del singolo keypoint tra un frame e l'altro nel seguente modo:

$$v_{k,[f_i,f_{i+1}]} = \frac{d}{\Delta t} = \frac{\sqrt{\left(x_{f_{i+1}} - x_{f_i}\right)^2 + \left(y_{f_{i+1}} - y_{f_i}\right)^2}}{\left(t_{f_{i+1}} - t_{f_i}\right)} \left[\frac{\text{pixel}}{\text{secondo}}\right] \tag{3.2}$$

dove *k* rappresenta il keypoint preso in esame, f_i e f_{i+1} rappresentano rispettivamente un frame ed il successivo, d rappresenta la distanza in pixel percorsa da un keypoint tra f_i e f_{i+1} e Δt rappresenta la differenza temporale tra i due frame, che per il frame rate dei video presi in esame è pari a $\frac{1}{30}$ secondo.
Una volta calcolata la velocità per ogni coppia di frame, per rendere più uniforme e smussare eventuali salti eccessivi nelle variazioni di velocità tra un frame e il successivo per ciascun keypoint, è stato utilizzato il filtro di Savitzky-Golay. Quest'ultimo è una tecnica di smoothing ampiamente utilizzata in analisi dei segnali e trattamento dei dati. In breve, il filtro di Savitzky-Golay scorre lungo la serie di dati e, per ciascun punto, calcola il valore medio pesato dei dati circostanti, utilizzando un polinomio di grado specificato e una finestra di lunghezza predefinita. Questo processo di approssimazione polinomiale aiuta a ridurre il rumore, mantenendo al contempo le caratteristiche del segnale di input [18]. Per poter utilizzare questo filtro, è stato quindi necessario impostare la lunghezza della finestra e il grado del polinomio. Tali parametri sono stati modulati di modo tale che i punti relativi alle velocità non venissero seguiti pedissequamente, ma che venisse mantenuto intatto l'andamento generale, smorzando il rumore presente e senza introdurre ritardi rispetto ai dati originali. Un esempio dell'applicazione di tale filtro è visibile in Figura 3.1.

$$v'_{k,[f_i,f_{i+1}]} = \text{filtro Savitzky-Golay}\left[v_{k,[f_i,f_{i+1}]}; \text{lunghezza finestra} = 13, \text{grado polinomio} = 5\right] \tag{3.3}$$

Avendo ora la velocità è possibile calcolare l'energia cinetica *K* tra f_i e f_{i+1}, in riferimento al singolo keypoint *k* (assumendo massa unitaria), nel seguente modo:

$$K_{k,[f_i,f_{i+1}]} = \frac{1}{2} \cdot \left(1 \cdot v'_{k,[f_i,f_{i+1}]}\right)^2 = \frac{1}{2} \cdot {v'_{k,[f_i,f_{i+1}]}}^2 \tag{3.4}$$

Eseguendo tale operazione per tutti i keypoint rilevanti, si arriva a ottenere il valore di energia cinetica totale relativo ai frame f_i e f_{i+1}:

$$K_{tot,[f_i,f_{i+1}]} = \sum_j K_{k_j,[f_i,f_{i+1}]} = \sum_j \frac{1}{2} \cdot {v'_{k,[f_i,f_{i+1}]}}^2 \tag{3.5}$$

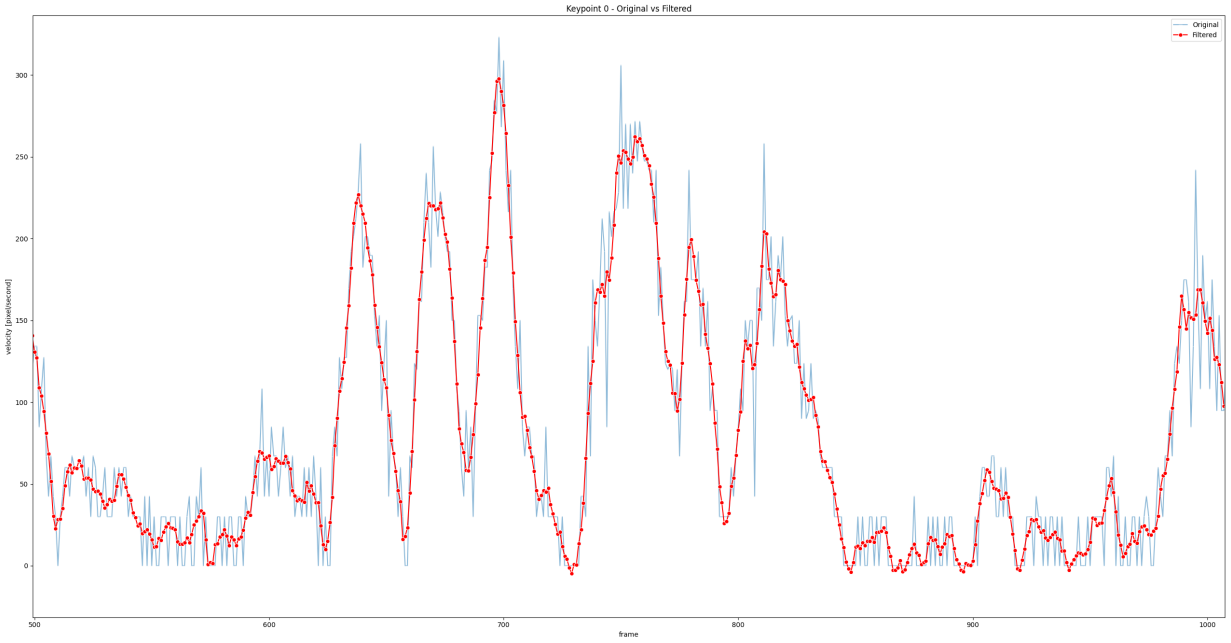


Figura 3.1: Grafico che illustra in blu la velocità istantanea e in rosso la velocità istantanea filtrata con un filtro di Savitzky-Golay. Il filtro è stato configurato con una lunghezza di finestra pari a 13 e un grado del polinomio pari a 5.
Questo confronto è relativo a un singolo keypoint all'interno di una porzione di video.

Avendo a disposizione l'energia cinetica totale per ogni coppia di frame di ognuno dei video presi in esame, è ora possibile definire l'algoritmo che andrà a estrarre i boundary tra un segmento e un altro e ne permetterà la valutazione.
Si procede iterando su ciascun video, escludendone uno alla volta dal dataset, in modo da poter applicare la tecnica della cross-validation. Questo video escluso sarà infatti utilizzato alla fine per testare la soglia selezionata. Del video invece appartenente all'attuale iterazione si considerano i quintili della distribuzione dell'energia cinetica totale, ossia i valori che dividono l'insieme dei dati ordinati in cinque parti uguali, ciascuna contenente il 20% dei dati. Si considerano i valori dei primi tre quintili ed essi saranno le soglie da testare. Pertanto per ognuna delle soglie si itera sul totale dei video, meno il video di test, e per ciascuno dei video si costituisce un vettore lungo quanto i frame del video, in cui si mette il valore 1 se il valore di energia cinetica totale di quel frame supera la soglia e 0 in caso contrario. Il passo successivo consiste nell'individuare i boundary: partendo dal vettore precedentemente costruito, si crea un nuovo vettore riempito di zeri e si inserisce 1 nella posizione corrispondente al primo frame con valore 1 dopo uno con valore 0, o viceversa. Si prosegue poi con il confronto con il groud truth per costruire la matrice di confusione, da cui si calcola la metrica F1 per valutarne le prestazioni, seguendo la tecnica descritta nella Sezione 3.1.
Una volta completata l'iterazione per ognuna delle soglie, si considera la media del valore di F1 ottenuto per ogni soglia sul totale dei video e si seleziona quella con la media maggiore. Successivamente, utilizzando la medesima procedura, si ottengono i boundaries del video di test utilizzando solamente la soglia selezionata e se ne calcola la F1.
Una volta concluso tale procedimento si avranno quindi a disposizione un totale di N F1 differenti, uno per ciascun video.
Attraverso l'Algoritmo 1 è possibile avere un'idea della struttura generale dell'algoritmo descritto, mentre le Figure 3.2, 3.3 e 3.4 permettono di visualizzarne l'applicazione attraverso un grafico.

Algorithm 1: soglia sull'energia cinetica

Input: Dataset di video
Output: Valori di F1 per ciascun video
foreach *video nel dataset* **do**
  Escludere un video dal dataset: il video di test;
  Estrarre i valori dei primi tre quintili della distribuzione dell'energia cinetica totale dal video corrente: le soglie;
  foreach *soglia* **do**
    foreach *video nel dataset escluso il video di test* **do**
      Calcolare il vettore di 1 e 0 relativi alla soglia;
      Calcolare, rispetto al vettore precedente, il vettore di 1 e 0 relativi ai boundary;
      Costruire la matrice di confusione facendo il confronto con il ground truth;
      Calcolare F1;
    end
  end
  Calcolare la media delle F1 per ogni soglia;
  Selezionare la soglia con la media maggiore;
  Estrarre i boundary del video di test utilizzando la soglia selezionata;
  Calcolare F1 per il video di test;
  Salvare il valore di F1 per il video corrente;
end

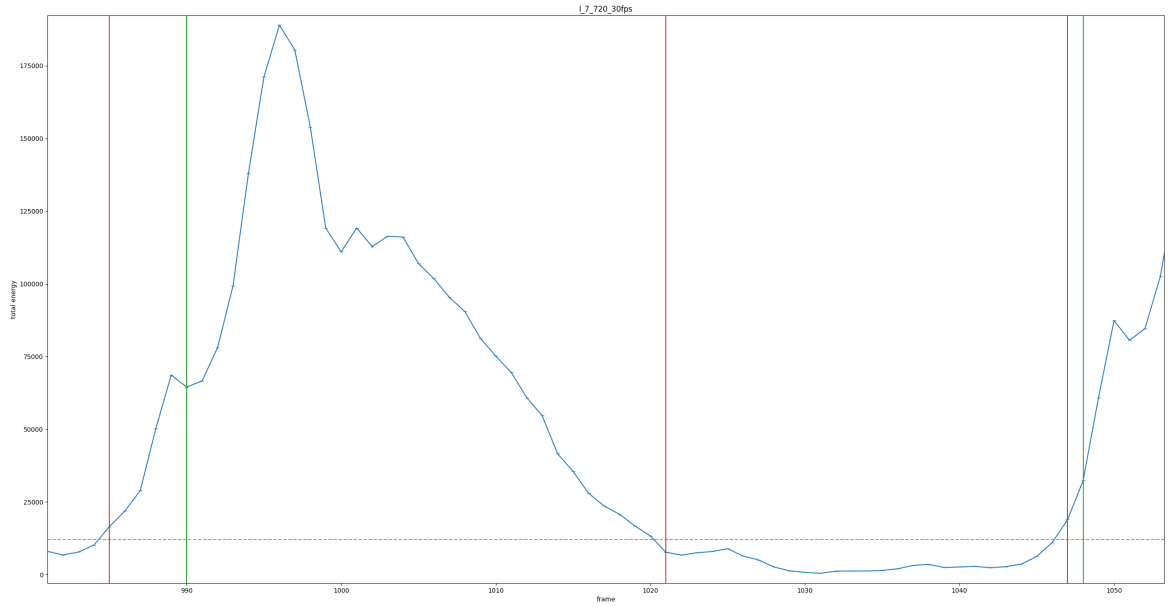


Figura 3.2: Grafico di un'azione eseguita all'interno di un video, in cui si possono osservare: in blu l'energia cinetica associata ai frame, in arancione la soglia selezionata, in verde i boundaries del ground truth e in rosso i boundaries calcolati.

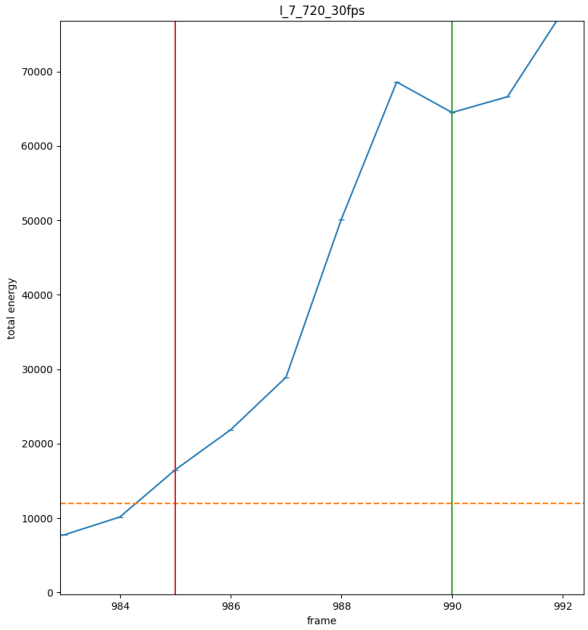


Figura 3.3: Parte iniziale dell'azione.

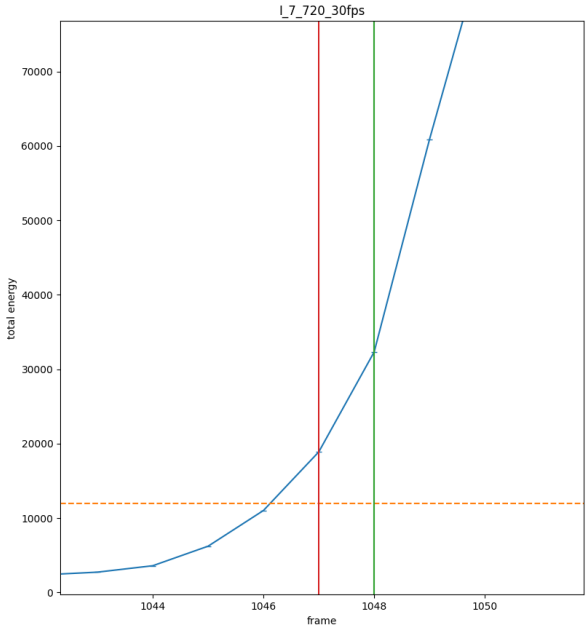


Figura 3.4: Parte finale dell'azione.

3.3 Metodo supervisionato: Support Vector Machine (SVM)

3.3.1 Cos'è una SVM

Le Support Vector Machine (SVM) rappresentano una classe di algoritmi di machine learning ampiamente utilizzati per problemi di classificazione e regressione. Il loro funzionamento si basa sulla ricerca di un iperpiano ottimale che separi al meglio le diverse classi dei dati. L'idea fondamentale è trovare quindi un iperpiano tale che la distanza tra esso e i punti più vicini di ogni classe, noti come vettori di supporto, sia massimizzata. Ciò significa che una SVM cerca di creare un confine decisionale che sia il più lontano possibile dai dati utilizzati per l'addestramento di entrambe le classi.

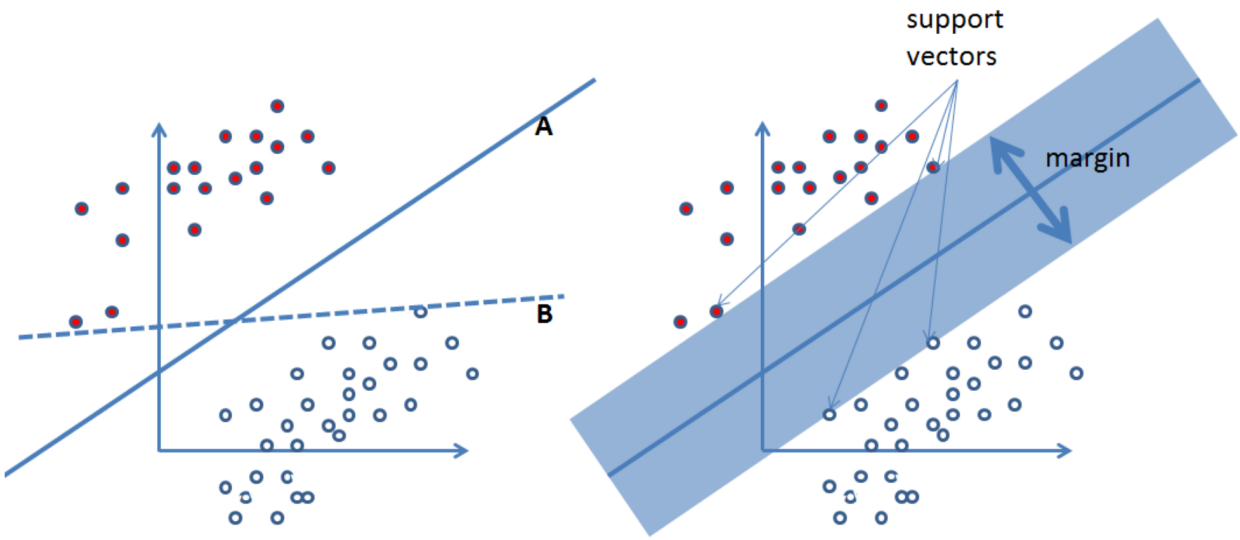


Figura 3.5: Esempio illustrativo, tratto da [4], del principio di base di una SVM.
Si evidenzia che il confine decisionale della linea A è più esteso rispetto a quello della linea B. Un confine decisionale ampio aumenta la probabilità che nuovi esempi siano correttamente classificati.
Inoltre, i vettori di supporto rappresentano i punti che toccano il margine del confine decisionale più ampio possibile.

Aspetto cruciale di questi modelli è il concetto di ”kernel trick” [4]. Tale tecnica consiste nel mappare i dati iniziali in uno spazio dimensionale più alto, dove la separazione tra le classi potrebbe essere più semplice, anche se i dati non sono linearmente separabili nello spazio originale. Ciò permette alle SVM di gestire efficacemente problemi di classificazione non lineari.
Nell'implementazione pratica delle SVM, è quindi necessario selezionare un kernel appropriato, come il kernel lineare, polinomiale o Gaussiano (RBF), in base alla natura del problema e dei dati. È inoltre importante ottimizzare gli iperparametri del modello stesso, quali il parametro di regolarizzazione C e il parametro del kernel, attraverso tecniche come la cross-validation.
Il primo controlla la penalizzazione per la classificazione errata sui dati di addestramento. Un valore più alto di C indica una penalizzazione maggiore per gli errori di classificazione, il che significa che il modello SVM cercherà di massimizzare la precisione sui dati di addestramento, a rischio di overfitting. Al contrario, un valore più basso di C implica una penalizzazione inferiore per gli errori di classificazione, consentendo al modello di adattarsi di più ai dati di addestramento, a rischio di underfitting.
Il secondo, invece, dipende dal tipo di kernel scelto e influenza la flessibilità del modello SVM nel trovare un iperpiano di separazione tra le classi, consentendo di adattarsi meglio alla struttura dei dati.
In ogni caso la scelta ottimale di questi parametri dipende dalla natura del problema e richiede spesso tecniche di ottimizzazione e validazione incrociata per trovare i valori migliori.
In generale le SVM trovano applicazione in una vasta gamma di settori, tra cui il riconoscimento di immagini, l'analisi del testo, la bioinformatica, la medicina e molto altro ancora. La loro versatilità e capacità di gestire problemi complessi le rendono una scelta popolare in molte aree di ricerca e applicazioni pratiche.

3.3.2 Segmentazione automatica tramite SVM

Questo approccio è stato ispirato da [15], che ha dimostrato l'efficacia dell'SVM nella segmentazione dei movimenti umani. Tuttavia, rispetto al lavoro originale, sono state apportate diverse modifiche per ottimizzare l'algoritmo per il dataset specifico utilizzato e per adattarlo ad un constesto di segmentazione ad eventi. In particolare, come approfondito successivamente, i dati utilizzati sono stati standardizzati per garantire una convergenza più rapida e una maggiore stabilità numerica. Inoltre non è stato utilizzato alcun tipo di aggregatore sui risultati finali, ma sono stati filtrati attraverso un filtro di post-processing.
Compreso quale sia il funzionamento di base di una SVM e le motivazioni del suo utilizzo, è ora possibile analizzare come tale strumento possa essere applicato all'interno del contesto della segmentazione automatica. L'obiettivo principale è quello di estrarre i boundaries di ogni evento e di conseguenza segmentare l'intera sequenza.
Come descritto precedentemente, tale algoritmo prevede una fase di apprendimento supervisionato il cui obiettivo è quello di trovare un iperpiano che separi, nel miglior modo possibile, i punti dati in classi diverse nello spazio delle caratteristiche. Questo iperpiano viene scelto in modo tale che sia massimizzata la distanza tra i punti più vicini delle classi e l'iperpiano stesso.

Nel caso preso in esame le classi sono due: **1** se è un boundary e **0** se non lo è, mentre invece le caratteristiche (*features*) che compongono appunto lo spazio delle caratteristiche sono:

- l'energia cinetica;
- la distanza tra il naso e il baricentro del tavolo;
- la distanza tra le mani;
- la distanza tra la mano sinistra e il naso;
- la distanza tra la mano destra e il naso;
- la distanza tra la mano sinistra e la spalla sinistra sommata alla distanza tra la mano sinistra e la spalla destra;
- la distanza tra la mano destra e la spalla sinistra sommata alla distanza tra la mano destra e la spalla destra;
- la distanza tra la mano sinistra e l'angolo superiore sinistro del tavolo;
- la distanza tra la mano destra e l'angolo inferiore destro del tavolo;
- la dimensione del soggetto rilevato;

Dato che le classi non sono linearmente separabili nello spazio delle caratteristiche, viene utilizzato il kernel RBF (Radial Basis Function), attraverso il quale i dati vengono mappati in uno spazio di dimensioni superiori, così da poter separare linearmente le classi:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\gamma||\mathbf{x}_i - \mathbf{x}_j||^2\right) + C \tag{3.6}$$

dove γ è il parametro del kernel che controlla la larghezza del picco della funzione gaussiana, $\mathbf{x}_i, \mathbf{x}_j$ sono i vettori di input, $||\mathbf{x}_i - \mathbf{x}_j||$ è la distanza euclidea tra i vettori di input e C è il parametro di regolarizzazione.

Il primo passo dell'algoritmo consiste nel calcolare, a partire dalle coordinate dei keypoints e utilizzando come metrica la distanza euclidea, il valore di ognuna delle feature elencate precedentemente, per ciascun frame all'interno di ogni video. Successivamente, per ogni video si itera su ciascun frame, partendo dal sesto, e si considera una serie temporale formata dal frame stesso più i 5 precedenti e i 5 successivi. Per ognuna di queste serie temporali si calcola la media, la varianza e la skewness di ogni feature, rispettivamente ai diversi frame considerati. La concatenazione di tali valori permette di ottenere un feature vector relativo alla serie temporale. Ognuno di questi feature vector va poi assegnato a una delle due classi: **1** se boundary, **0** se non boundary. Per farlo si confronta il punto centrale della serie temporale con il ground truth. Se in quest'ultimo la classe è la 1, allora essa viene direttamente assegnata al feature vector, se la classe è 0 si guarda se tra i cinque frame precedenti o successivi nel ground truth ce n'è uno assegnato alla classe 1, in tal caso si assegna la classe 1 al feature vector, altrimenti la classe 0. Alla fine di tale procedimento si ottiene per ogni video una porzione di dataset, composta da feature vectors classificati.
Il passo successivo consiste nel comporre i training set e i test set che verranno utilizzati all'interno della SVM. Si procede quindi con l'iterare sul totale dei video e ad ogni iterazione i feature vectors di uno dei video vanno a comporre il test set, mentre i feature vectors dei video rimanenti, prima di comporre il training set vengono bilanciati. Per farlo si selezionano tutti feature vectors associati alla classe 1 e successivamente si selezionano un numero casuale di feature vectors associati alla classe 0 pari alla media del numero di feature vectors associati alla classe 1 sul totale dei video. Alla fine di tale processo si ottiene quindi un training set e un test set per ogni video all'interno del dataset.
Infine si prosegue con l'applicazione del modello di machine learning e per farlo si itera su ciascuna coppia

(training set; test set) precedentemente composta. Per garantire che l'algoritmo funzioni in modo efficiente e accurato, le feature utilizzate vengono standardizzate. Tale pratica, consiste nel trasformare queste ultime affinché abbiano media zero e varianza uno, ciò assicura che ognuna di esse contribuisca in modo equilibrato al modello, prevenendo la dominanza di features con scale maggiori. Inoltre, questo passaggio facilita la convergenza dell'algoritmo durante l'addestramento, migliorando l'efficienza computazionale. In aggiunta alla standardizzazione, viene applicata l'Analisi delle Componenti Principali (PCA), mantenendo il 90% della varianza totale iniziale, per ridurre la dimensionalità del dataset. Tale pratica trasforma le features originali in un nuovo insieme di componenti principali non correlate, mantenendo la maggior parte della variabilità dei dati. Questo non solo semplifica il modello e riduce il rischio di overfitting, ma migliora anche l'efficienza computazionale, rendendo la fase di addestramento della SVM più rapida e meno esigente in termini di risorse. Per l'addestramento della SVM, vengono forniti il training set bilanciato e differenti coppie di parametri γ e C, utilizzati per massimizzarne le performance. Dopo l'addestramento, il modello viene testato utilizzando i features vectors contenuti nel test set. Infine, le prestazioni di quest'ultimo vengono valutate calcolando l'F1, utilizzando il metodo descritto nella Sezione 3.1.
Osservando l'Algoritmo 2 è possibile avere un'idea dei passaggi principali che sono stati effettuati.

Algorithm 2: Support Vector Machine

Input: Coordinate dei keypoints, Ground truth, Set di video
Output: valori di F1 e parametri migliori per ogni iterazione
foreach *Video nel dataset* **do**
  Estrarre le feature di ogni frame;
  Comporre i feature vector di ogni serie temporale;
end
foreach *Video nel dataset* **do**
  Comporre il test set;
  Comporre il training set bilanciato;
end
foreach *Video nel dataset* **do**
  Standardizzare il training set;
  Applicare la PCA mantenendo il 90% della varianza totale;
  Addestrare la SVM con il training set e le differenti combinazioni di coppie di parametri γ e C:

γ	0.001	0.01	0.1	1
C	0.1	1	10	100

  ;
  Estrarre i boundary dal test set utilizzando il modello addestrato;
  Calcolare F1 per il test set;
end

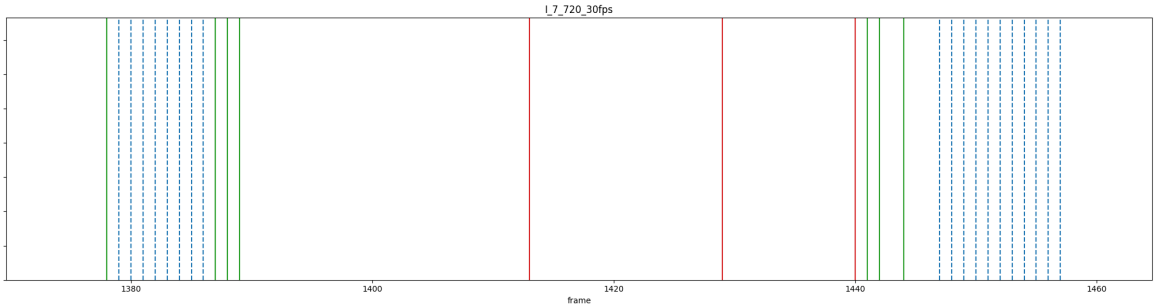


Figura 3.6: Grafico della segmentazione di una parte di video in cui si possono osservare: i boundaries relativi ai feature vectors classificati, indicati in blu tratteggiato; successivamente all'estrazione della SVM, i boundaries corretti in verde e quelli errati in rosso.

A seguito dell'osservazione di una recall alta, ma di una precisione bassa nei risultati preliminari, viene applicato un filtro post-processing sui risultati della SVM, e prima del calcolo della F1, così da migliorare la precisione

dei boundaries rilevati. Il filtro in questione esamina ogni boundary appartenente alla segmentazione effettuata dalla SVM e per ognuno di essi analizza la classe dei 5 frame precedenti e dei 5 successivi. Nel caso in cui rilevi la presenza di altri boundaries all'interno di questa finestra, classifica come boundary solamente il frame nella posizione pari alla media delle posizioni dei boundaries rilevati.
Il risultato che si ottiene è ben visibile in Figura 3.7.

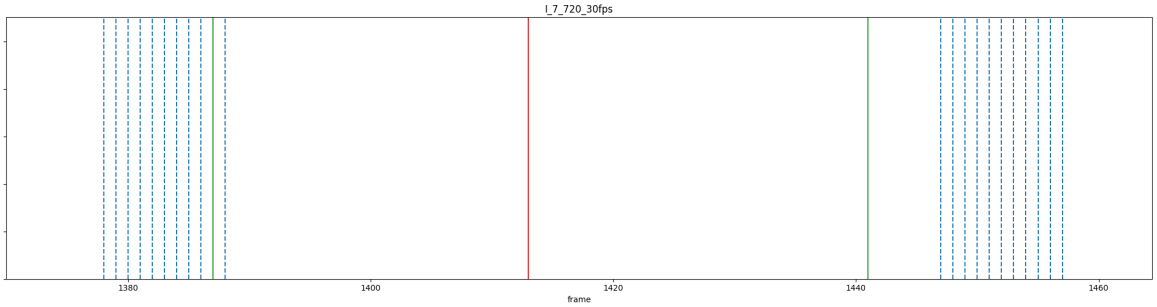


Figura 3.7: Grafico della stessa parte di video presente in Figura 3.6, una volta applicato il filtro.

3.4 Metodo non supervisionato: Pruned Exact Linear Time (PELT)

3.4.1 Cos'è PELT

PELT [12] è un algoritmo di analisi delle serie temporali, dalle quali estrae i punti di cambiamento basandosi sul cambiamento che avviene all'interno dei dati. Più precisamente tale algoritmo individua i punti in cui le caratteristiche statistiche dei dati cambiano significativamente e per farlo ottimizza una funzione di costo che bilancia la fedeltà del modello ai dati con la complessità del modello stesso. All'interno di questa funzione troviamo due componenti principali:

- **costo di adattamento dei dati**, che misura quanto bene il modello rappresenti i dati all'interno di ciascun segmento;
- **penalità per il numero di segmenti**, che ha l'obiettivo di prevenire il sovra-adattamento.

La formula generale della funzione di costo è:

$$C(K) = \sum_{k=1}^{m} C(Y_{t_{k-1}:t_k}) + \beta m \tag{3.7}$$

dove $C(K)$ è il costo totale per un set di segmenti K, $C(Y_{t_{k-1}:t_k})$ è il costo per il segmento k, e β è il termine di penalità che controlla la complessità del modello.

Questo algoritmo ha un costo computazionale che è lineare con il numero di osservazioni e funziona quasi in tempo reale, rendendolo anche adatto all'utilizzo con grandi dataset.

3.4.2 Segmentazione automatica tramite PELT

Inteso quale sia il funzionamento dell'algoritmo PELT, è ora possibile analizzarne l'applicazione all'interno del contesto della segmentazione automatica ad eventi.
Prima di tutto è bene osservare che le classi a cui associare i diversi frame e le feature utilizzate dal metodo ora in esame, sono le stesse utilizzate dal metodo supervisionato 3.3. A differenza di quest'ultimo però, non vi è una fase di apprendimento, ma l'estrazione dei boundaries avviene direttamente, senza la necessità di avere esempi già classificati su cui fare affidamento.
Compresa tale precisazione ci si può addentrare all'interno dell'implementazione. Il primo passo dell'algoritmo consiste nel'iterare sul totale dei video e ad ogni iterazione escluderne uno dall'analisi, così da poter testare i risultati finali dell'iterazione in corso. Ad ogni iterazione si considerano quindi tutti video meno che quello

di test. Per ognuno di questi video si estraggono, attraverso PELT, i boundaries relativi a ognuna delle feature considerate. Per farlo vengono testati differenti configurazioni di parametri e per ognuna di esse si ottiene la classe di appartenenza di ogni frame del video in esame. Ottenuti i risultati di tutte le feature per un singolo video, si procede unificando i risultati a parità di configurazione. Si ottiene dunque, rispetto al video in esame, un segmentazione per ognuna delle configurazioni del PELT, in cui un frame viene considerato come boundary se almeno una delle feature lo ha considerato come tale. Conclusa l'estrazione per ognuno dei video all'interno dell'iterazione, si valuta quale sia la configurazione di parametri migliore e per farlo si confronta il risultato ottenuto da ciascuna configurazione, per ciascun video, con il rispettivo ground truth. Tale valutazione utilizza il metodo descritto nella Sezione 3.1. Viene infine utilizzato PELT, con la configurazione di parametri con F1 maggiore, per valutare la segmentazione sul video di test escluso all'inizio dell'iterazione.
Osservando l'Algoritmo 3 è possibile avere un'idea dei passaggi principali, mentre attraverso la Figura 3.8 è possibile osservare un esempio del risultato ottenuto.

Algorithm 3: PELT

```
Input: Features, Ground truth, Set di video
Output: valori di F1 per ogni iterazione
foreach Video nel dataset do
    Escludere un video: video di test;
    foreach Video non di test do
        foreach Features do
            Estrarre i boundary utilizzando PELT;
        end
        Unificare i risultati a parità di configurazione;
    end
    Valutare la configurazione migliore;
    foreach Features do
        Estrarre i boundary utilizzando PELT con la configurazione migliore, sul video di test;
    end
    Unificare i risultati;
    Calcolare F1;
end
```

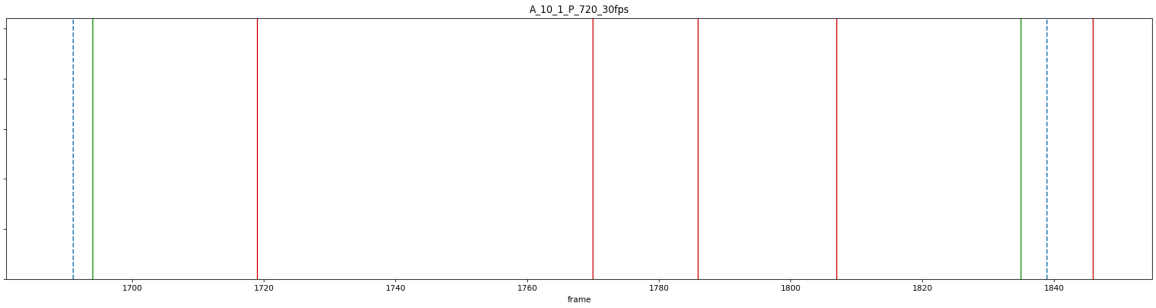


Figura 3.8: Grafico della segmentazione di una parte di video, in cui si possono osservare relativamente al ground truth i boundaries in blu tratteggiato, mentre relativamente all'estrazione effettuata attraverso PELT, in verde i boundaries corretti e in rosso quelli errati.

Capitolo 4

Analisi dei risultati

All'interno di questo capitolo vengono analizzati i risultati ottenuti dai vari algoritmi implementati, con una discussione dettagliata delle loro prestazioni. Per ciascun algoritmo, vengono esaminati i risultati ottenuti su ogni video, utilizzando una strategia di leave-one-video-out. In particolare, le performance sono valutate tramite le metriche: precision, recall e F1-score. A partire da questi valori, vengono calcolate la distribuzione, la media e la deviazione standard per fornire una visione complessiva delle performance.

4.1 Metodo a soglia

Per quanto riguarda il primo algoritmo sviluppato 3.2, sono stati ottenuti i risultati visibili nella Tabella 4.1, la quale mostra l'efficacia dell'algoritmo nell'analisi dei video in termini di Precision, Recall e F1-score.

Video	Precision	Recall	F1
A_1_2_P_720_30fps	0.80	0.65	0.71
A_2_2_P_720_30fps	0.88	0.63	0.73
A_7_2_P_720_30fps	0.74	0.67	0.70
A_10_1_P_720_30fps	0.86	0.75	0.80
A_11_1_P_720_30fps	0.75	0.79	0.77
A_13_1_P_720_30fps	0.85	0.66	0.74
C_1_720_30fps	0.72	0.74	0.73
C_2_720_30fps	0.71	0.76	0.73
C_3_720_30fps	0.63	0.73	0.68
C_4_720_30fps	0.68	0.68	0.68
C_6_720_30fps	0.66	0.67	0.67
C_7_720_30fps	0.80	0.67	0.73
I_1_720_30fps	0.72	0.64	0.68
I_2_720_30fps	0.67	0.79	0.72
I_4_720_30fps	0.72	0.75	0.74
I_5_720_30fps	0.78	0.64	0.71
I_6_720_30fps	0.82	0.58	0.68
I_7_720_30fps	0.68	0.70	0.69
Media	0.75	0.69	0.72
Deviazione Standard	0.07	0.06	0.03

Tabella 4.1: Risultati ottenuti dal metodo a soglia.

Analizzando i risultati ottenuti da questo metodo si osserva che:

- la precisione varia da un minimo di 0.63 (C_3_720_30fps) a un massimo di 0.88 (A_2_2_P_720_30fps), suggerendo che, in generale, l'algoritmo è piuttosto accurato nell'identificare correttamente i veri positivi.
- La recall varia da 0.58 (I_6_720_30fps) a 0.79 (A_11_1_P_720_30fps), mostrando una buona capacità dell'algoritmo di rilevare i veri positivi, anche se in alcuni casi c'è margine di miglioramento.
- L'F1-score varia da 0.67 (C_6_720_30fps) a 0.80 (A_10_1_P_720_30fps), ciò indica che l'algoritmo mantiene un buon equilibrio tra precisione e recall, rendendolo efficace all'interno del contesto della segmentazione automatica dei video.

Complessivamente, l'algoritmo basato sulla soglia dell'energia cinetica mostra una buona performance su vari video. La variabilità nei valori di precisione, recall e F1-score tra i diversi video utilizzati suggerisce che in alcuni casi, forse per le specifiche caratteristiche dei movimenti analizzati, potrebbero presentarsi sfide particolari nel segmentare correttamente. Nonostante ciò, i video con i migliori risultati (come A_2_2_P_720_30fps e A_10_1_P_720_30fps) evidenziano che attraverso l'utilizzo di tale strategia si possono raggiungere alte prestazioni in condizioni ottimali.

4.2 Metodo supervisionato

Relativamente al secondo algoritmo sviluppato 3.3, l'analisi parte dai valori di Precision, Recall e F1-score ottenuti inizialmente, i quali sono visibili nella Tabella 4.2. Una volta applicato il filtro di post-processing si ottengono invece i risultati presenti in Tabella 4.3.

Video	Precision	Recall	F1
A_1_2_P_720_30fps	0.29	0.56	0.38
A_2_2_P_720_30fps	0.27	0.55	0.36
A_7_2_P_720_30fps	0.30	0.41	0.35
A_10_1_P_720_30fps	0.22	0.81	0.35
A_11_1_P_720_30fps	0.20	0.83	0.32
A_13_1_P_720_30fps	0.24	0.64	0.35
C_1_720_30fps	0.20	0.69	0.31
C_2_720_30fps	0.18	0.63	0.27
C_3_720_30fps	0.18	0.70	0.29
C_4_720_30fps	0.18	0.73	0.29
C_6_720_30fps	0.18	0.77	0.29
C_7_720_30fps	0.20	0.60	0.30
I_1_720_30fps	0.25	0.71	0.37
I_2_720_30fps	0.26	0.65	0.37
I_4_720_30fps	0.23	0.78	0.35
I_5_720_30fps	0.20	0.59	0.30
I_6_720_30fps	0.24	0.78	0.36
I_7_720_30fps	0.24	0.60	0.34
Media	0.23	0.66	0.33
Deviazione Standard	0.04	0.10	0.03

Tabella 4.2: Risultati ottenuti dal metodo supervisionato: SVM.

I risultati senza il filtro mostrano una recall alta e una precisione bassa, indicando che il classificatore sta individuando un alto numero di falsi positivi. Per questo motivo viene applicato il filtro di post-processing, come

Video	Precision	Recall	F1
A_1_2_P_720_30fps	1.0	0.43	0.60
A_2_2_P_720_30fps	1.0	0.47	0.64
A_7_2_P_720_30fps	1.0	0.36	0.53
A_10_1_P_720_30fps	1.0	0.65	0.79
A_11_1_P_720_30fps	1.0	0.61	0.76
A_13_1_P_720_30fps	1.0	0.52	0.68
C_1_720_30fps	1.0	0.48	0.65
C_2_720_30fps	1.0	0.42	0.59
C_3_720_30fps	1.0	0.45	0.62
C_4_720_30fps	1.0	0.55	0.71
C_6_720_30fps	1.0	0.56	0.72
C_7_720_30fps	0.99	0.41	0.58
I_1_720_30fps	1.0	0.59	0.74
I_2_720_30fps	1.0	0.54	0.70
I_4_720_30fps	1.0	0.62	0.76
I_5_720_30fps	1.0	0.47	0.64
I_6_720_30fps	1.0	0.65	0.79
I_7_720_30fps	1.0	0.49	0.66
Media	1.0	0.52	0.68
Deviazione Standard	0.00	0.08	0.07

Tabella 4.3: Risultati ottenuti applicando il filtro di post-processing ai risultati di classificazione della SVM.

descritto nella Sezione 3.3, che ridimensiona il numero di boundaries trovati, impedendo che essi siano troppo vicini. Dopo la sua applicazione, la precisione migliora sensibilmente, riducendo il numero di falsi positivi e incrementando così la qualità complessiva delle predizioni.
Nello specifico, considerando i risultati ottenuti successivamente all'applicazione del filtro di post-processing, si osserva che:

- La precisione risulta estremamente alta in tutti i video, variando tra 0.99 (C_7_720_30fps) e 1.0 per tutti gli altri video, indicando che l'algoritmo riesce a identificare correttamente quasi tutti i veri positivi.
- La recall mostra una maggiore variabilità, da un minimo di 0.36 (A_7_2_P_720_30fps) a un massimo di 0.65 (I_6_720_30fps), suggerendo che l'algoritmo ha difficoltà a rilevare tutti i positivi in alcuni casi.
- L'F1-score varia tra 0.53 (A_7_2_P_720_30fps) e 0.79 (A_10_1_P_720_30fps e I_6_720_30fps), ciò indica che l'algoritmo mantiene un equilibrio tra precisione e recall, sebbene non così forte come nel caso del primo algoritmo.

Il secondo algoritmo, con i dovuti accorgimenti, complessivamente mostra prestazioni molto elevate in termini di precisione, ma variabilità nel recall e, di conseguenza, nell'F1-score. Questa variabilità indica che l'algoritmo può beneficiare di ulteriori ottimizzazioni per migliorare il rilevamento dei veri positivi in alcuni scenari.

4.3 Metodo non supervisionato

I risultati dei valori di Precision, Recall e F1-score ottenuti dal terzo algoritmo 3.4 sono riportati nella Tabella 4.4.

Video	Precision	Recall	F1
A_1_2_P_720_30fps	0.20	0.29	0.24
A_2_2_P_720_30fps	0.22	0.25	0.24
A_7_2_P_720_30fps	0.20	0.27	0.23
A_10_1_P_720_30fps	0.27	0.47	0.34
A_11_1_P_720_30fps	0.25	0.32	0.28
A_13_1_P_720_30fps	0.17	0.23	0.20
C_1_720_30fps	0.15	0.26	0.19
C_2_720_30fps	0.16	0.26	0.20
C_3_720_30fps	0.16	0.20	0.18
C_4_720_30fps	0.13	0.19	0.16
C_6_720_30fps	0.40	0.39	0.40
C_7_720_30fps	0.27	0.41	0.31
I_1_720_30fps	0.11	0.18	0.14
I_2_720_30fps	0.09	0.14	0.11
I_4_720_30fps	0.15	0.29	0.20
I_5_720_30fps	0.18	0.25	0.21
I_6_720_30fps	0.24	0.35	0.29
I_7_720_30fps	0.20	0.27	0.23
Media	0.20	0.28	0.23
Deviazione Standard	0.07	0.08	0.07

Tabella 4.4: Risultati ottenuti dal metodo non supervisionato.

Relativamente ai risultati ottenuti dal terzo algoritmo si osserva che le performance sono generalmente basse su tutti i fronti:

- La precisione varia tra 0.09 (I_2_720_30fps) e 0.40 (C_6_720_30fps), indicando che l'algoritmo ha una performance complessivamente bassa nell'identificare correttamente i veri positivi.
- La recall varia tra 0.14 (I_2_720_30fps) e 0.47 (A_10_1_P_720_30fps), mostrando che l'algoritmo ha una discreta capacità di rilevare i positivi, ma con margini di miglioramento significativi.
- L'F1-score varia tra 0.11 (I_2_720_30fps) e 0.40 (C_6_720_30fps), indicando che il modello ha una performance complessivamente bassa nel mantenere un equilibrio tra precisione e recall.

Analizzando nel complesso i risultati ottenuti, l'algoritmo PELT mostra una performance inferiore rispetto agli altri algoritmi esaminati. La variabilità nei valori di precisione, recall e F1-score suggerisce che ci sono aree significative di miglioramento per aumentare l'efficacia dell'algoritmo nel segmentare correttamente i video.

4.4 Sintesi delle prestazioni

Utilizzando un grafico a violino, visibile in Figura 4.1, è possibile visualizzare la densità e la distribuzione dei valori di F1-score ottenuti per i tre algoritmi testati. Questo approccio ci permette di apprezzare il comportamento complessivo di ciascun algoritmo sull'intero set di video testati.

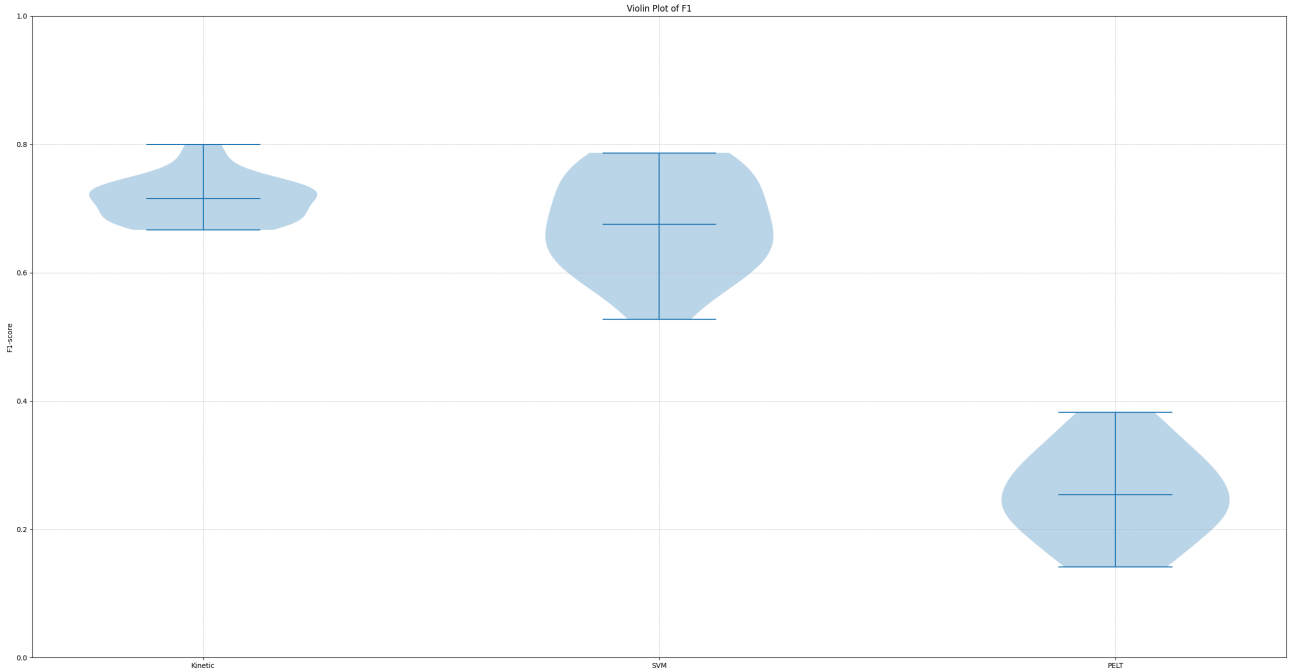


Figura 4.1: Grafico a violino dei valori F1-score dei tre algoritmi.

La forma del grafico relativo all'algoritmo basato sull'energia cinetica indica che le F1-score sono distribuite uniformemente attorno a una media di 0.72, con una leggera maggiore densità verso valori più alti. La deviazione standard di 0.03 suggerisce che le prestazioni del modello sono abbastanza consistenti attraverso i vari video testati. La simmetria del grafico attorno alla media indica che non ci sono skewness significative, non vi è una predominanza di valori particolarmente alti o bassi, evidenziando una distribuzione bilanciata. Questo risultato mostra che l'algoritmo basato sull'energia cinetica ha una performance solida e consistente, mantenendo un buon equilibrio tra precisione e recall in diverse condizioni, come suggerito dalla variazione ristretta delle F1-score ottenute.
Passando al grafico relativo all'SVM, le F1-score sono distribuite in maniera piuttosto uniforme attorno a una media di 0.68, con una deviazione standard di 0.07, indicando una maggiore variabilità rispetto all'algoritmo precedente. La distribuzione non perfettamente simmetrica suggerisce una leggera skewness verso valori più bassi di F1-score. In sintesi, il secondo algoritmo basato su SVM mostra una performance solida in termini di precisione, ma con una variabilità nella recall che influisce sui valori di F1-score. Questo suggerisce che l'SVM può essere migliorato per ottenere una performance più consistente attraverso i vari video testati.
Infine, il grafico relativo a PELT mostra che le F1-score sono distribuite attorno a una media di 0.23, con una deviazione standard di 0.07, suggerendo una notevole variabilità delle prestazioni del modello. Questo indica che PELT ha una performance meno solida rispetto agli altri algoritmi, con una variazione ampia dei valori di F1-score. Di conseguenza, PELT necessita di ottimizzazioni per migliorare la consistenza delle prestazioni.

Conclusioni

Nella presente tesi, viene esplorata l'efficacia di tre algoritmi distinti per la segmentazione automatica ad eventi: soglia sull'energia cinetica, Support Vector Machine (SVM) e Pruned Exact Linear Time (PELT). I risultati sperimentali hanno mostrato che i primi due algoritmi hanno ottenuto prestazioni robuste, mentre il terzo algoritmo ha invece ottenuto performance inadeguate. In questo capitolo finale, vengono discussi i risultati ottenuti da ogni algoritmo, enfatizzando le potenziali cause delle prestazioni inferiori dell'algoritmo PELT e suggerendo direzioni future per migliorarne l'efficacia.

L'algoritmo basato sulla soglia dell'energia cinetica ha dimostrato una buona capacità di identificazione dei boundaries. Attraverso un'accurata selezione delle soglie e una valutazione iterativa su vari video, si è potuto ottenere un equilibrio tra precision e recall, con valori di F1-score che attestano la robustezza del metodo. Questo risultato conferma che, sebbene semplice, l'algoritmo a soglia può essere un metodo efficace per la segmentazione ad eventi in contesti specifici. Tale metodo rimane comunque limitato ad una singola caratteristica estraibile dai video e nel caso in cui quest'ultima non possa essere estrapolata, tale algoritmo risulta inapplicabile.
L'uso della SVM ha migliorato ulteriormente le prestazioni di segmentazione ottenute dal primo algoritmo. La combinazione di diverse feature ha permesso di catturare meglio le dinamiche dei movimenti e delle interazioni con gli oggetti. Il processo di addestramento, la selezione ottimale degli iperparametri e l'applicazione di un filtro di post-processing, hanno contribuito ad ottenere valori di F1 superiori ed in linea con la segmentazione effettuata da parte di un essere umano. Questo dimostra la capacità delle SVM di gestire complessità e variabilità nei dati, raggiungendo un buon livello di generalizzazione del processo di segmentazione.
Al contrario dei due precedenti algoritmi, l'algoritmo PELT ha fornito risultati meno soddisfacenti, nonostante le sue potenzialità teoriche. I valori di F1-score ottenuti sono stati inferiori rispetto agli altri due algoritmi e, anche nei casi migliori, non abbastanza elevati da permetterne una valutazione finale positiva. L'applicazione di un filtro di post-processing in questo caso non avrebbe permesso un aumento delle performance, dato che la recall non risulta elevata e quindi il problema non è solamente legato al numero di falsi positivi individuati.
La principale causa di questa performance inadeguata potrebbe essere attribuita al fatto che l'algoritmo, non prevedendo una fase di addestramento su dati già classificati, individui i boundary dove avvengono i cambiamenti all'interno delle features utilizzate, ma essi siano leggermente spostati rispetto alla finestra di frames considerata per il confronto con il ground truth. Come evidenziato in [7], la precisione e l'affidabilità della segmentazione effettuata manualmente sono cruciali per la valutazione delle prestazioni degli algoritmi di segmentazione automatica. Nel caso della presente tesi, possibili errori umani o incoerenze nelle segmentazioni manuali potrebbero aver introdotto rumore nei dati utilizzati per la valutazione delle prestazioni dell'ultimo algoritmo, rendendola imprecisa.
I risultati ottenuti indicano che l'algoritmo a soglia sull'energia cinetica e l'SVM sono metodi efficaci per la segmentazione ad eventi. Tra questi, l'SVM ha dimostrato una performance superiore e più naturale, grazie all'utilizzo di tecniche derivate dall'Event Segmentation Theory (EST) per la selezione delle caratteristiche utilizzate. Applicando i principi dell'EST, tali caratteristiche sono state selezionate in modo da riflettere i momenti chiave e i cambiamenti significativi nei video. In particolare, l'EST aiuta a identificare i punti di cambiamento che corrispondono a transizioni naturali tra azioni o eventi, migliorando così la precisione del modello nel riconoscere e segmentare queste transizioni. Questa selezione di caratteristiche, basata su una comprensione più profonda del comportamento umano e della percezione degli eventi, contribuisce a migliorare la capacità dell'SVM di segmentare i video in modo più accurato e coerente rispetto al primo algoritmo. Nonostante anche l'algoritmo PELT sfrutti tali caratteristiche, esso richiede un'attenzione particolare alla qualità della segmentazione manuale per raggiungere risultati comparabili.

Future ricerche potrebbero concentrarsi su un miglioramento di questo aspetto, utilizzando la segmentazione manuale effettuata da molteplici individui per ridurre la soggettività e aumentare l'accuratezza della valutazione delle performance dell'algoritmo. Riuscire a raggiungere una segmentazione automatica accurata è cruciale per molte applicazioni pratiche, dalla sorveglianza alla medicina. Migliorare questi algoritmi potrebbe portare a significativi progressi in queste aree, consentendo di automatizzare processi critici e di ottenere analisi più precise e affidabili dei dati video.

Bibliografia

[1] Samaneh Aminikhanghahi e Diane J Cook. «A survey of methods for time series change point detection». In: *Knowledge and information systems* 51.2 (2017), pp. 339–367.

[2] Abbas Ataya et al. «Improving activity recognition using temporal coherence». In: *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE. 2013, pp. 4215–4218.

[3] Dare A Baldwin et al. «Infants parse dynamic action». In: *Child development* 72.3 (2001), pp. 708–717.

[4] Roberto Battiti e Mauro Brunato. *The LION way. Machine Learning* plus *Intelligent Optimization*. LIONlab, University of Trento, Italy, 2023, pp. 101–118. url: `http://intelligent-optimization.org/LIONbook/`.

[5] Christopher JC Burges. «A tutorial on support vector machines for pattern recognition». In: *Data mining and knowledge discovery* 2.2 (1998), pp. 121–167.

[6] Eleonora Ceccaldi. «CEST: a Cognitive Event based Semi-automatic Technique for behavior segmentation.» Tesi di dott. University of Genoa, Italy, 2021, pp. 9–11.

[7] Eleonora Ceccaldi e Gualtiero Volpe. «Towards a cognitive-inspired automatic unitizing technique: a feasibility study». In: *Proceedings of the International Conference on Advanced Visual Interfaces*. 2020, pp. 1–5.

[8] Staffan Ekvall, Daniel Aarno e Danica Kragic. «Online task recognition and real-time adaptive assistance for computer-aided machine control». In: *IEEE Transactions on Robotics* 22.5 (2006), pp. 1029–1033.

[9] Gutemberg Guerra-Filho e Yiannis Aloimonos. «A language for human action». In: *Computer* 40.5 (2007), pp. 42–51.

[10] Minh Hoai, Zhen-Zhong Lan e Fernando De la Torre. «Joint segmentation and classification of human actions in video». In: *CVPR 2011*. IEEE. 2011, pp. 3265–3272.

[11] Winfried Ilg et al. «On the representation, learning and transfer of spatio-temporal movement characteristics». In: *International Journal of Humanoid Robotics* 1.04 (2004), pp. 613–636.

[12] Rebecca Killick, Paul Fearnhead e Idris A Eckley. «Optimal detection of changepoints with a linear computational cost». In: *Journal of the American Statistical Association* 107.500 (2012), pp. 1590–1598.

[13] Jessica E Kosie e Dare Baldwin. «Attentional profiles linked to event segmentation are robust to missing information». In: *Cognitive Research: Principles and Implications* 4.1 (2019), pp. 1–18.

[14] Simon Kozina, Mitja Lustrek e Matjaz Gams. «Dynamic signal segmentation for activity recognition». In: *Proceedings of International Joint Conference on Artificial Intelligence, Barcelona, Spain*. Vol. 1622. 2011, pp. 15–22.

[15] Jonathan Feng-Shun Lin, Vladimir Joukov e Dana Kulic. «Human motion segmentation by data point classification». In: *2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE. 2014, pp. 1–6.

[16] Lie Lu, Hong-Jiang Zhang e Hao Jiang. «Content analysis for audio classification and segmentation». In: *IEEE Transactions on speech and audio processing* 10.7 (2002), pp. 504–516.

[17] Lawrence R Rabiner. «A tutorial on hidden Markov models and selected applications in speech recognition». In: *Proceedings of the IEEE* 77.2 (1989), pp. 257–286.

[18] Ronald W Schafer. «What is a Savitzky-Golay filter?[lecture notes]». In: *IEEE Signal processing magazine* 28.4 (2011), pp. 111–117.

[19] Dian Shao et al. «Intra-and inter-action understanding via temporal action parsing». In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020, pp. 730–739.

[20] Hua-Ping Wan e Yi-Qing Ni. «Binary segmentation for structural condition classification using structural health monitoring data». In: *Journal of Aerospace Engineering* 32.1 (2019), p. 04018124.

[21] Jeffrey M Zacks, Nicole K Speer e Jeremy R Reynolds. «Segmentation in reading and film comprehension.» In: *Journal of Experimental Psychology: General* 138.2 (2009), pp. 307–327.

[22] Jeffrey M Zacks e Khena M Swallow. «Event segmentation». In: *Current directions in psychological science* 16.2 (2007), pp. 80–84.

[23] Tianxiang Zhang et al. «Imu based single stride identification of humans». In: *2013 IEEE RO-MAN*. IEEE. 2013, pp. 220–225.